


NO. f27eca6dd72629ac | 2026-05-15 19:26:11

- 题目: 悉尼通信2203-李松桃0515-副本.docx
- 作者: 佚名
- 检测所属单位: -

📄 论文字符数: 44531 📄 论文页数: 55 📊 表格数量: 10 🖼️ 图片数量: 3

检测结果



74.18%

疑似AIGC生成占比

25.82%

人工撰写占比


结果分布

序号	章节	疑似AIGC生成文字/章节总字数	疑似AIGC生成章节占比	人工撰写占比
1	摘要	299/750	39.0%	61.0%
2	1 绪论	3734/5309	70.0%	30.0%
3	2 PPE目标检测基础理论	3868/6199	62.0%	38.0%
4	3 基于C2HiLo-YOLO的工地PPE检测算法研究及部署	7273/8590	84.0%	16.0%
5	4 C2HiLo-YOLO检测算法实验验证	6839/11016	62.0%	38.0%
6	结论	2057/2059	99.0%	1.0%

*注:格式规范的情况下可准确识别章节,若论文中无章节,可能会识别有误。

片段分布

■ 疑似AIGC生成 ■ 人工撰写



文字标注

■ 疑似AIGC生成 ■ 人工撰写

悉尼通信2203-李松桃0515-副本.docx



东北大学 秦皇岛分校
Northeastern University at Qinhuangdao

毕业论文

基于YOLO的工地个人防护装备检测算法研究

院 别	悉尼智能科技学院
专业名称	通信工程
班级学号	202219226
学生姓名	李松桃
指导教师	宋昕

2025年12月

郑重声明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名： 日期：

基于YOLO的工地个人防护装备检测算法研究

摘要

建筑行业施工环境复杂、安全风险高，因此正确佩戴个人防护装备（Personal Protective Equipment, PPE）是预防施工事故的关键手段。然而传统人工巡检方式存在效率低等问题，已无法满足当前工地安全管理需求。随着深度学习的发展，以YOLO为代表的实时目标检测算法为工地PPE自动化检测提供了新方案，但现有检测模型在工地场景中仍然面临小目标检测精度低、复杂背景下易漏检误检等痛点。针对上述问题，本文开展了基于YOLO的工地个人防护装备检测算法研究，提出了轻量化的C2HiLo-YOLO检测模型。

本研究以YOLOv11n为基础模型，通过引入HiLo高低频注意力机制，设计了HiLoBlock特征增强单元，并结合跨阶段局部网络思想构建C2HiLo模块，该模块通过高低频特征解耦与协同优化的方式，同时捕捉边缘、纹理等细粒度特征和场景全局上下文。本文基于该模块构建C2HiLo-YOLO，该模型保留了原YOLO的轻量化结构，同时增强了对小目标和遮挡目标的检测能力。

本文在两个公开PPE数据集——Construction-PPE与DPPE上进行了对比实验与消融实验。实验结果显示，C2HiLo-YOLO在两个数据集上均达到SOTA水平，且证明了C2HiLo模块和各子模块的有效性。同时，实验还证明C2HiLo模块仅引入了少量的计算开销，这使得YOLOv11n模型的轻量化特性得以保持。本研究进一步完成了模型的可视化分析，其结果证明C2HiLo-YOLO在训练过程中收敛速度快；得到的产物模型的类别区分能力强；在小目标、密集遮挡、复杂背景等工地典型场景中，检测效果良好。在此基础上，本文完成了模型的工程化部署，构建了包含模型推理服务与前端展示界面的PPE检测技术原型，实现了算法从训练到应用的落地。

关键词：工地安全；个人防护装备检测；YOLO算法；深度学习；目标检测

目录

1 绪论

1.1 研究背景

1.2 研究意义

1.3 国内外研究现状

1.3.1 早期的目标检测方法

1.3.2 基于深度学习的两阶段检测方法

1.3.3 基于深度学习的单阶段检测方法

1.3.4 适用于PPE任务的目标检测方法

- 1.4 本文主要内容和结构安排
- 2 PPE目标检测基础理论
 - 2.1 卷积神经网络
 - 2.2 经典深度学习目标检测方法介绍
 - 2.2.1 R-CNN系列算法
 - 2.2.2 SSD算法
 - 2.2.3 YOLO系列算法
 - 2.3 基于深度学习的PPE目标检测算法
 - 2.4 本章小结
- 3 基于C2HiLo-YOLO的工地PPE检测算法研究及部署
 - 3.1 YOLOv11n模型选择依据及分析
 - 3.1.1 Backbone网络
 - 3.1.2 Neck网络
 - 3.1.3 Head网络
 - 3.2 C2HiLo: 基于高频和低频特征的注意力机制的改进模块
 - 3.2.1 HiLo注意力机制介绍
 - 3.2.2 C2HiLo模块的设计与实现
 - 3.3 C2HiLo-YOLO模型整体结构与优势
 - 3.3.1 C2HiLo-YOLO 模型整体结构设计
 - 3.3.2 C2HiLo-YOLO 模型的核心结构优势
 - 3.4 系统部署和实施
 - 3.5 本章小结
- 4 C2HiLo-YOLO检测算法实验验证
 - 4.1 数据集
 - 4.1.1 Construction-PPE数据集
 - 4.3.1 Dataset of Personal Protective Equipment数据集
 - 4.2 实验设置
 - 4.3 实验评价指标
 - 4.4 实验结果
 - 4.4.1 Construction-PPE数据集结果
 - 4.4.2 Dataset of Personal Protective Equipment数据集结果
 - 4.4.3 消融实验
 - 4.5 C2HiLo-YOLO模型可视化分析
 - 4.5.1 模型收敛性分析

4.5.2 类别识别混淆矩阵分析

4.5.3 检测结果定性可视化分析

4.6 本章小节

结 论

致 谢

参考文献

附 录

附录A

中文译文A

1 绪 论

1.1 研究背景

现有研究[1]指出，建筑行业对国民经济和基础设施建设具有重要支撑职能。由于施工环境复杂、作业风险高，该行业被列为最危险的行业之一[2-3]。坠落、物体打击、碰撞经常导致施工人员伤亡，而正确佩戴个人防护装备（Personal Protective Equipment, PPE）能有效防范上述事故[4]。比如，安全帽能缓冲坠物对头部的冲击，反光背心在低能见度或复杂场景中强化工人可视性。所以PPE的规范使用直接关联到事故发生率与伤亡程度，也因此，确保工人合规佩戴PPE，成为了工地安全管控的关键环节。

传统安全管理主要依赖人工巡检和定点传感器[5]。然而，施工区域扩大、环境复杂化之后，人工巡检暴露出效率低下、覆盖不全、成本高昂等缺陷，难以满足现代施工环境的安全需求。因此研发能够自动、实时监测工人PPE穿戴情况的检测技术，对提升工地安全管控水平、规避事故具有实际价值，PPE检测的自动化程度决定了安全管理的响应时效与覆盖广度。

自深度学习兴起后，卷积神经网络在图像任务中快速进步[6-7]。以YOLO（You Only Look Once）为代表的目标检测算法，因为推理延迟低被广泛应用[8-10]。工地安全监测场景也开始采用这类算法，为PPE佩戴情况的自动化检测开辟了新路径[11-12]。因此，本文将重点研究如何将YOLO算法应用于工地个人防护装备检测系统中，以提高工地安全管理的智能化水平。

1.2 研究意义

YOLO检测方案在工地个人防护装备监控场景中具备理论实践兼备[13]。系统实时监控工人安全帽、反光背心等装备佩戴合规性。YOLO视觉检测算法快速识别违规行为，发现违规即触发预警，降低安全事故概率，推动工地安全管理的智能化升级[3, 14-16]。自动化检测替代人工巡查后，企业人力与时间投入将明显减少，检测效率与准确率同步提升[17-18]。YOLO本身速度快、实时性强，能适应复杂多变的工地现场环境[19-20]。对YOLO目标检测模型进行参数调优与网络结构调校后，系统推理速度与检测精度均有增强，为工地安全管控提供更可靠管理提供更可靠技术支持。

本研究开发一套兼具高精度与高效率的工地个人防护装备检测系统，满足实际工地对检测精度与实时响应的双重要求。建筑工地环境变化剧烈，进出人员流动频繁，安全隐患在瞬间出现。工地PPE监测方案须在极短时间内识别违规，识别后直接触发报警、留存记录或通知人员介入。这类应用场景下，系统必须兼具精准识别能力与低推理时

延。PPE检测中存在大量小目标，现有YOLO算法对此类小目标的检出率往往不高[20]。

具体而言，研究目标包括以下几个方面。收集高质量数据集，涵盖不同场景下工人佩戴与未佩戴防护装备的图像数据，对这些数据进行人工筛选与标注，为后续模型训练提供基础。选择适合工地环境的YOLO版本作为基础模型，结合注意力机制、续训策略等手段进行改进，提升模型在复杂场景下的检测性能。搭建模型训练环境，调整超参数与优化训练策略，进一步提高检测精度与推理速度。将训练好的模型部署至实际平台，实现快速推理[21]。

图1.1 目标检测的三种方法

1.3 国内外研究现状

PPE检测算法属于图像目标检测算法的一个分支。后者从复杂图像数据中识别并定位目标[22-23]。目标检测构成了计算机视觉的基础任务之一，它识别图像中目标的类别，并确定其位置[22-23]。过去十年间，深度学习技术兴起后，目标检测算法经历了深刻的范式变革。这一历程主要分为三种方法：基于手工特征的传统方法、两阶段检测和单阶段检测。三种方法的结构与差异如图1.1所示。以下阐述包括PPE检测算法在内的目标检测算法研究成果。

1.3.1 早期的目标检测方法

早期的目标检测方法遵循手工特征提取加传统机器学习分类的技术路线。研究人员依据领域经验手工设计图像边缘、颜色、纹理等底层视觉特征。HOG[24-25]与SIFT[26]是其中最具代表性的两类手工特征。HOG对图像局部单元格进行梯度方向直方图统计，据此刻画目标的轮廓与形状，该手工特征曾是行人检测领域的主流方案。SIFT则提取关键点描述子，这些手工设计的描述子具备旋转与尺度不变性，目标尺度变化和视角偏转时仍能保持稳定。手工提取的底层特征被输入支持向量机[27]（Support Vector Machines, SVM）分类器，SVM通过构建最优分类超平面完成不同类别目标的区分。这类方法的局限性相当明显，在背景简单的实验室条件下，此类手工特征加分类器的方案尚能获得一定检测效果，但对复杂实际场景表现较差。此外，手工特征设计高度依赖专家经验，检测需求一旦变化，过去的方案难以快速适配新的场景[22]。

1.3.2 基于深度学习的两阶段检测方法

深度学习兴起后，CNN在图像分类任务上的巨大成功为检测问题提供了全新思路[28-30]。研究人员将CNN特征提取能力引入检测任务，区域提议驱动的两阶段检测框架由此出现。R-CNN[31]（Regions with CNN features）开创了兩阶段检测方法：用启发式算法（如选择性搜索[32]）生成大量候选区域，经裁剪缩放至固定尺寸后各自输入预训练CNN提取特征，由支持向量机完成分类。Fast R-CNN[33]优化了这一流程：共享整张图像的CNN特征图计算，避免对每个候选区域单独提取特征。速度得到显著提升。Faster R-CNN[34]将启发式候选区域生成替换为专用的区域提议网络（Region Proposals Network, RPN），RPN与检测网络共享大部分权重，端到端框架内完成候选区域生成与目标分类回归。Mask R-CNN[35]在Faster R-CNN基础上增加并行掩码预测分支，引入RoIAlign层解决特征错位问题，实现目标检测与像素级分割两项任务。

R-CNN家族作为两阶段检测器的经典代表，其检测精度极高。然而这种高精度源于两阶段结构的串行级联设计，层层累积之下计算瓶颈也因此形成[36]。R-CNN系列模型的推理延迟居高不下，吞吐量因而受限，使得R-CNN系列模型难以满足实时应用对高吞吐量的严苛要求。

1.3.3 基于深度学习的单阶段检测方法

由于两阶段的方法速度慢，目标检测的研究重心转向单阶段检测器。这类检测器合并特征提取、目标分类与边

界框回归至一个网络，在特征图的多个位置直接预测，检测流程由此简化。SSD (Single Shot MultiBox Detector) [37]是第一个被广泛认可的单阶段检测器。YOLO[38]提出完整地看待图像并一次性预测边界框和类别概率，将整个检测过程视为一个单一的回归问题。端到端设计简化了训练与推理流程，检测速度与精度得到提升。早期YOLO版本在小目标检测精度上不足，其设计理念的革新促使大量研究者跟进，后续单阶段检测器的发展均以YOLO为参照。后续YOLO版本引入新型网络结构和训练技巧，检测精度逐渐接近两阶段检测器，某些任务上甚至实现超越[39-42]。单阶段检测器尤其是YOLO系列，在实时目标检测场景中被广泛部署，速度与精度接近或超越两阶段检测器，目标检测技术由此变得更高效、更实用。

1.3.4 适用于PPE任务的目标检测方法

本文研究目标检测算法在PPE识别任务中的优化。PPE识别任务和其他目标检测任务主要有两个区别。第一，检测目标较小[19]。工地检测依赖现场监控摄像头，这些摄像头通常摆放在施工区域远处或高处，因此检测目标在图像上的显示相对较小。第二，对算法的实时性要求强[43-44]。为满足以上两个要求，现代PPE检测算法通常在单阶段目标检测算法基础上进行修改，并针对小目标进行增强处理[12, 16, 17]。

近年来，YOLOv系类模型也被大量布设于施工场景之中。秦妍等人将YOLOv4检测框架同DeepSort关联，专门判别施工人员的安全装备穿戴合规性[4]。这项方案依托创新的数据增强技术并引入IoU分析，大幅提升了召回率与精确率两项核心指标，在高密度交叉作业工况下依然维持稳定检测表现。李华等人则采用通道注意力机制对YOLOv5检测网络进行优化[45]，重点强化了安全帽与反光衣的特征提取能力，使检测精度得到显著提升。

上述方法在部分环境下表现良好，但在复杂场景下仍存在局限。背景复杂、目标密集或光照不均匀时，检测精度会有所下降[19]，检测精度的不足严重限制了这些算法在工地环境中的实际部署。设备计算资源的限制也使得模型轻量化与实时推理成为关键瓶颈[1, 46]。孙光灵等人[47]提出使用知识蒸馏的轻量化安全帽检测模型KD-YOLO，通过大幅削减参数量和浮点运算数降低了模型部署成本，但检测精度仍有提升空间，精度与轻量化之间的权衡尚未完全解决。Malaikrisanachalee等人[19]提出的ESPCN-YOLO框架融合超分辨率增强与YOLOv8目标检测模型，在低光照、远距离及小目标等挑战性条件下显著提升了PPE检测精度，检测精度的提升同时支持实时推理与自动告警，为复杂工业场景下的鲁棒检测提供了新思路。

以上研究针对YOLO网络的增强方案都没有考虑到了YOLO网络自身的性能缺陷。这些方法对YOLO网络主干未做实质性改动，仅靠外部模块叠加，局部缓解了YOLO网络在推理中暴露的瓶颈。架构层面的固有限制依然没有被打破。本研究选择直接改造YOLO网络内部结构，设计更高效的空间注意力模块，让YOLO网络在特征响应图上逐空间位置精准分配权重，引导网络聚焦关键区域实现对PPE精度的上升并且保持较低的算力开销。

1.4 本文主要内容和结构安排

本文设计并实现了一个使用YOLO框架的工地个人防护装备检测算法，全文共七章。内容涵盖该检测算法所使用的技术与工具、检测算法的完整结构与各项参数、目标检测算法及其改进策略，并对算法性能进行了全面测试。本文的各章结构安排如图1.2所示。

图1.2 论文组织结构图

第1章绪论介绍研究背景。本章从实操与理论两条线索交代PPE检测的研究背景。PPE检测涉及两条主线：工程现场对安全防护装备的迫切需求，目标检测技术的持续演进。需求与技术的交汇，驱动了PPE检测这一方向的研究进

展。PPE检测面临的具体挑战包括目标尺度差异大、环境遮挡严重和实时性要求高。传统目标检测方法（如基于手工特征的分类器）、基于深度学习的一阶段检测器（YOLO系列）与二阶段检测器（Faster R-CNN）、轻量化模型以及注意力机制的应用，都是已有代表性成果。每类方法各有优势与不足。轻量化模型降低计算开销但牺牲部分特征提取能力。注意力机制增强关键区域响应却增加模型复杂度。对全文研究内容进行概括，厘清各章节的组织结构与逻辑衔接，为后续章节的深入阐述奠定基础。

第2章阐述目标检测理论基础。目标检测是计算机视觉的核心任务之一，本章阐述其基本运算机制。卷积层通过滑动窗口提取局部特征。池化层通过下采样压缩特征图维度。全连接层将分布式特征映射到样本标记空间。卷积层、池化层、全连接层三者协同工作，支撑起整个目标检测算法的特征提取环节。R-CNN系列经历从区域提议到端到端训练的演进，特征共享程度逐步加深，计算效率同步改善。SSD利用多尺度特征图检测不同尺寸目标。YOLO从v1的网格划分发展到v8的anchor-free设计，检测速度与精度持续获得提升。这些算法的迭代搭建起现代目标检测的技术框架，有力地支撑了本文改进模型的提出与PPE检测任务的实现。

第3章介绍一种兼顾轻量化与高精度的PPE识别方法。工地环境中个人防护装备检测面临远距离小尺寸目标的像素信息过少和复杂背景引发大量误检的问题。针对这些难点，本研究选择YOLOv11n轻量模型作为起点。YOLOv11n模型参数量小、推理速度快，但其C2PSA模块对高频细节与低频语义的区分能力弱，在工地场景下容易丢失安全帽边缘等关键纹理的轮廓。为突破这一瓶颈，本文引入HiLo注意力机制，对特征图沿通道维度采用分而治之的策略，将其拆解为高频与低频两个子频带。基于这一思路设计了HiLoBlock特征增强模块。C2HiLo模块实现了高频与低频子频带之间的互补协同，有效补全了遗漏的特征信息。该改进在仅增加轻量计算量的前提下，显著提升了模型对远距离、小尺寸PPE目标的识别能力，为复杂工地环境下的实时安全监测提供了有效的算法支持。

第4章为实验环节，介绍了所用数据集与PPE检测任务、和具体的训练配置。通过统一PyTorch平台，完整复现YOLOv5、YOLOv8、YOLOv11等基准模型，同时实现本文提出的C2HiLo-YOLO检测模型。将所提出模型在该平台上进行多次实验，其结果与该领域经典论文和最新论文结果进行对比，取得了当前较高的性能，在多项关键指标上达到SOTA。

第5章为全文结论。系统梳理了研究脉络，归纳提出的C2HiLo-YOLO方案的核心创新与技术亮点，阐明该方法对保障作业人员安全的实际价值。同时也客观分析当前PPE检测模型在极端光照、严重遮挡等复杂场景下的识别瓶颈。并对未来研究方向进行展望，为后续探索提供可行技术路径。

2 PPE目标检测基础理论

目标检测负责识别图像中目标的类别与位置，是计算机视觉的核心任务。深度学习兴起后，CNN方法[48]主导了这一技术范式。CNN最初为图像分类设计，随后被迁移到目标检测任务中，这一拓展为后续目标检测算法奠定了理论基础。PPE检测任务改造通用目标检测算法，通过适配PPE的具体场景来满足实际应用需求，属于目标检测的子任务。

2.1 卷积神经网络

目标检测框架中，CNN负责特征提取，充当网络的骨干。输入原始图像后，检测算法将其送入VGG-16[48]或ResNet50[49]这类CNN网络，从中提取高维且语义信息丰富的特征表示。卷积层对特征图逐级抽象，其表征能力制约着后续定位与分类任务的性能上限。骨干网络的特征提取能力与效率，在很大程度上影响着目标检测器的整体表

现。

卷积构成CNN的基本运算。可学习的卷积核在输入特征图上滑动，计算局部区域加权和，从而提取特定特征。卷积核可以看作一个小矩阵，它扫描整个输入图像，逐步生成新的输出特征图。经过卷积，输出特征图的尺寸变化会影响网络的计算量以及后续层的输入规格。输出特征图的尺寸由以下通用公式给出：

$$h = \left\lfloor \frac{H - K + 2P}{S} \right\rfloor + 1 \quad (2.1)$$

$$w = \left\lfloor \frac{W - K + 2P}{S} \right\rfloor + 1 \quad (2.2)$$

式中， h 和 w 分别表示输出特征图的高度和宽度， H 和 W 分别表示输入图像的高度和宽度， K 表示卷积核的大小， P 表示填充的像素数， S 表示步长， $\lfloor \cdot \rfloor$ 表示向下取整。

若不进行填充操作（ $P=0$ ），特征图尺寸随网络深度增加逐层衰减。为控制这种空间尺寸缩减速度，或保持输入输出尺寸一致，常见策略是在特征图边界执行补零。这种零填充（zero-padding）方式，在步长设为特定数值时，可使输出尺寸与输入尺寸完全一致。步长决定卷积核在特征图上的滑动步幅。步幅增大时，输出特征图的尺寸随之减小，计算开销显著降低，同时每个神经元的感受野扩大。感受野的扩大使卷积核能捕获更大范围的输入信息。

池化完成降采样（downsampling）功能，通过下采样压缩特征图的空间尺寸，同时保留最强的激活响应。这种降采样是一种高效的空間压缩手段。广泛应用的池化方法是最大池化（max pooling），即在每个池化窗口内取最大值作为输出。该操作简洁且计算高效。与卷积的尺寸计算规则相似，池化能有效增大感受野、降低计算复杂度，并为模型提供一定程度的平移不变性。这种平移不变性对图像分类等任务至关重要，原因在于它使网络对输入中目标的微小偏移不敏感。这种不敏感性提升了模型对目标位置变化的鲁棒性。

感受野也是CNN中的核心概念。某一特定层中，单个神经元所能观测到的原始输入图像区域大小，被称为感受野。换言之，神经元的激活值仅由该感受野范围内的像素点决定。总层数、各层卷积核大小、步长及填充方式共同决定整个网络的感受野尺寸。较大的感受野使模型能捕获更广的上下文信息，这对于区分外观相似但所处场景不同的物体非常关键。广阔的上下文对定位和识别被遮挡物体同样不可或缺。感受野大小直接影响模型对小物体的检测能力，若小物体尺寸小于其所在层级的感受野，则该层特征难以有效区分该物体。一些研究开始主动设计与优化感受野，例如将锚框尺寸与有效感受野大小进行匹配，显著提升了小物体的检测性能。理解并管理好感受野，对设计高效目标检测网络而言非常关键。

2.2 经典深度学习目标检测方法介绍

2.2.1 R-CNN系列算法

R-CNN系列算法的两阶段处理中，第一步产生高质量候选区，第二步对候选区执行分类。这种分离式设计虽以一定速度作为代价，但前期对候选区的精细筛选使检测精度通常高于单阶段检测器。两阶段范式最终由Faster R-CNN [34]集大成，实现端到端训练与检测，成为目标检测技术演进史上的重要里程碑。

R-CNN[31]开创了两阶段范式。R-CNN使用选择性搜索算法利用颜色、纹理、形状和尺寸等底层视觉线索，在输

入图像上生成约2000个候选矩形框。候选区逐一裁剪并缩放到 227×227 固定尺寸，批量送入AlexNet[50]等CNN网络抽取特征。抽取出的特征向量输入SVM分类器执行分类。图2.1展示了R-CNN算法步骤。

尽管R-CNN取得了巨大的成功，但它存在两个问题：一是选择性搜索作为一个独立的外部模块，与深度学习流程脱节，计算耗时，不是一个端到端的操作；二是特征提取过程存在严重的冗余，因为大量重叠的候选区域在本质上对应着图像的同一部分，却需要重复地通过CNN进行前向传播。

图2.1 R-CNN算法步骤

冗余是R-CNN面临的核心瓶颈。Fast R-CNN[33]引入了RoI Pooling层，整张图像一次性通过CNN完成前向传播后，生成了供全体候选区共享的高维特征图，选择性搜索输出的候选区坐标被映射到该特征图上，再按预设的固定尺寸完成池化，输出统一大小的特征向量，重复提取的开销不复存在。

Faster R-CNN[34]在Fast R-CNN基础上，在候选区生成环节用区域提议网络（RPN）替代了选择性搜索。RPN与主干网络共享卷积层权重，直接在共享特征图上滑窗预测锚框，覆盖多种尺度和宽高比。这样做使得候选区生成不依赖独立算法，有利于端到端联合训练。Faster R-CNN交替优化RPN和检测头，从而实现两个阶段的协同工作。

2.2.2 SSD算法

SSD[37]由Wei Liu等人于2016年提出，在深度学习目标检测的单阶段检测器中占有一席之地。R-CNN系列等两阶段框架依赖候选区域生成与区域分类分离的流程，SSD则取消了这一设计，一次前向传播直接输出目标类别和边界框位置。检测速度与精度由此达成实际可用的折中，SSD因此被用于多项实时目标检测任务。

SSD的默认框机制与多尺度特征图检测是其主要创新。SSD主干网络选用VGG16，其后串联多个额外卷积层，由此形成的特征图金字塔从高分辨率延伸到低分辨率。不同尺度的特征图承担不同大小目标的检测：浅层特征图分辨率高、感受野小，小目标检测由它们负责；深层特征图语义信息丰富、感受野大，大目标识别更依赖这些层。模型对多尺度目标的适应能力，正是通过这种协同检测机制得到增强。

SSD引入的“默认框”（即先验框，Prior Box）机制与Faster R-CNN中RPN的锚框在原理上相似，但在更多尺度和长宽比上实施了稠密采样。每个特征图的空间位置格点上预设一组固定尺寸和比例的默认框，卷积操作直接输出每个默认框的类别置信度，以及相对于真实框的偏移量（包含中心点坐标与宽高的调整）。随后采用非极大值抑制合并重叠的默认框预测结果，输出最优检测结果。SSD还采用Hard Negative Mining负样本挖掘策略专门用于应对正负样本极度不平衡的问题。大量默认框不包含目标（即负样本），若放任不管，模型将被海量简单负样本主导。SSD在训练时按置信度排序，仅保留少量难分类负样本参与损失计算，此举能够加速收敛并改善检测精度。损失函数由分类损失和定位损失两部分构成，通过加权系数联合优化。

相较于两阶段方法，SSD的最大优势在于检测速度快、结构简洁、易于端到端训练，特别适用于对实时性要求较高的应用场景，如视频监控、自动驾驶和移动端部署。早期SSD版本在小目标检测上表现较弱，对低质量预测框的抑制能力有限。后续改进模型（如DSSD[51]、DF-SSD[52]等）引入反卷积结构增强语义信息或优化NMS策略，进一步提升了检测性能。

2.2.3 YOLO系列算法

Joseph Redmon等人于2016年提出了YOLO[38]，这一工作为单阶段检测器建立了新范式。R-CNN系列将检测任务拆解为区域提议、特征提取、分类与定位等若干独立环节，YOLO则另辟蹊径——它把目标检测直接定义为一个回归

问题，单次前向传播便能同时完成所有目标的定位和分类。速度与简洁贯穿这一框架的设计始终，“只看一次”的实时检测由此开始。

YOLO把输入图像切成 $S \times S$ 个网格，落到哪个网格内的目标就由哪个网格负责。每个网格输出B个边界框，框内写入中心坐标(x, y)、宽高(w, h)和置信度这5个数值，网格还需预测C个类别的条件概率。最终预测结果构成一个 $S \times S \times (B \times 5 + C)$ 的张量输出。模型生成的候选框之间大量重叠，非极大值抑制（Non-Maximum Suppression, NMS）随后上场，按置信度得分对检测框排序，保留得分最高的框，剔除所有与其交并比（Intersection over Union, IoU）超过阈值的重叠框，干净地输出最终结果。图2. 1给出了YOLOv1经由Backbone网络到Head网络的形状演变过程（YOLOv1中 $S=7$, $B=2$, $C=20$ ）。

YOLO的网格化设计将整张图像划分为均匀网格，这种划分参数使并行处理成为可能，区域搜索的串行计算被完全规避，检测速度获得显著提升。YOLO中每个网格仅负责预测固定数量的边界框（比如YOLOv1中一个网格只负责预测两个边界框），只对中心落入该网格的目标负责，这一机制虽然将检测问题转化为了一个单阶段的端到端问题，也导致早期YOLO版本在检测小目标或密集目标时容易出现漏检。后续YOLO版本采用多尺度检测策略，对此进行了优化。

图2. 1 YOLOv1的算法步骤和经过网络的形状变化

YOLOv2（YOLO 9000）[39]在快速检测框架之上引入了锚框机制。YOLOv2预先定义一批不同尺度与宽高比的先验锚框，这些锚框作为边界框回归的参考基点提供给模型训练使用，随机初始化带来的收敛难题得到有效疏解。YOLOv2使用全卷积网络替换了全连接层，使模型能够接收任意分辨率的输入图像执行多尺度训练，对不同数据分辨率的适应性因此明显增强。

YOLOv3[40]采用多尺度特征融合与网络架构优化后，小目标与密集目标的检测能力得到提升。借鉴FPN（Feature Pyramid Network）思想，该模型在深层、中层、浅层特征图上分别检测大、中、小目标：深层特征图语义信息丰富但分辨率低，适合检测大目标；浅层特征图分辨率高但语义较弱，适合小目标。跨层连接与上采样操作实现了不同尺度特征的融合。YOLOv3将主干网络替换为Darknet-53，该网络借助残差结构加深层次并保持计算效率，增强了特征表达能力。

YOLOv4[41]集成了多种技术，精度与速度的平衡得到改善，被广泛部署于工业场景。其骨干网络采用CSPDarknet53，跨阶段局部网络结构减少了计算冗余，保持特征表达能力并降低参数量。Mosaic数据增强方法随机拼接四张训练图像并调整亮度、饱和度等属性，增加了样本多样性。特征融合阶段结合了PANet（Path Aggregation Network）与SPP（Spatial Pyramid Pooling）模块。前者以自底向上与自顶向下的双向融合加强多尺度信息传递，后者以不同尺度的池化操作聚合空间上下文，二者提升了对不同尺度目标的检测能力。

后续YOLO版本持续在轻量化、效率与极端场景适应性上探索，通过模型裁剪、动态标签分配、Transformer结构引入等技术，进一步推动实时检测边界。尽管早期YOLO版本因网格划分限制在小目标检测上存在不足，但凭借其极致的速度优势、简洁的端到端设计、以及持续的技术迭代，YOLO系列已深入实时障碍物检测和视频监控等工业场景，成为兼顾效率与性能的核心检测方案。表2. 1总结了YOLO系列个算法的特点和演变过程。

表2. 1 YOLO系列算法总结表

版本	年份	Backbone	主要创新与特点
----	----	----------	---------

YOLOv1[38]	2015	简单的CNN网络	初代框架：将检测视为回归问题，实时性革命。
YOLOv2[39]	2016	Darknet-19	引入Anchor Boxes机制和Batch Normalization。
YOLOv3[40]	2018	Darknet-53	多尺度预测；引入FPN，使用逻辑回归损失。
YOLOv4[41]	2020	CSPDarknet53	集成Bag of Freebies，引入Mosaic数据增强。
YOLOv5[42]	2020	CSPDarknet	引入自适应锚框，PyTorch实现，生态完善。
YOLOv6[53]	2022	EfficientRep	硬件加速友好：引入重参数化结构，Anchor-free。
YOLOv7[54]	2022	E-ELAN	可训练的模型缩放：引入辅助头，优化模型缩放策略。
YOLOv8[55]	2023	C2f (ELAN-N)	Anchor-Free；解耦头设计；支持分类/检测/分割多任务。
YOLOv9[56]	2024	GELAN	提出PGI（可编程梯度信息）机制。
YOLOv10[57]	2024	NanoScaleNet	NMS-Free：一致双重分配策略，消除后处理NMS。
YOLOv11[58]	2024	C3k2/ C2PSA	引入C3k2模块和PSA模块，优化小目标检测。
YOLOv12[59]	2025	YOLO-TR	引入区域注意力(RA)，R-ELAN结构。

2.3 基于深度学习的PPE目标检测算法

YOLO目标检测算法虽然在多个方面优于传统方法，对小目标检测精度不足的问题却始终存在，PPE检测任务中这一短板尤为明显。PPE目标检测是小目标检测场景的典型代表，挑战集中在目标尺寸小、密集分布、背景干扰强以及姿态多样性。当前PPE识别领域的研究重点落在注意力机制上，通过引入不同类型的注意力模块提升对密集小目标的检测能力。注意力机制包含通道注意力机制与空间注意力机制两种类别。




图2.2 SENet通道注意力示意图

通道注意力机制显式建模各通道间的相互依赖关系。网络为每条通道学习一个自适应权重，据此进行加权，强化重要通道、抑制非重要通道。以SENet[60]为例，该网络通过压缩与激励两个步骤完成特征重标定。压缩操作沿空间维度聚合全局信息，生成一个全局特征标识符；激励模块对该标识符施加非线性变换，借助sigmoid函数产生通道权重向量，再用该权重向量对原始特征图进行逐通道加权，实现通道维度上的特征重标定，增强有用通道、抑制无用通道。这种机制显著提升了PPE边缘纹理等细微特征的代表能力。在低分辨率条件下，模型仍能有效捕捉安全帽等小目标的轮廓信息。

图2.3 Attention机制示意图

为了建模空间维度上的相互依赖关系，空间注意力捕捉输入数据中不同空间位置之间的关联，以选择关键的空间区域。在各类注意力实现中，最经典的是Attention机制[61]，其注意力函数将查询Q与一组键值对（KV）映射至

一个输出向量 O ，其中 Q 、 K 、 V 和 O 均为向量。输出 O 是 V 的加权和，每个 V 对应的权重由 Q 与相应 K 的相似性函数计算得出。图2.3展示了Attention机制的注意力权重分配流程。空间注意力引导模型关注PPE实例所在的空间位置，利用空间位置信息帮助区分重叠目标，降低因目标遮挡导致的漏检率。当前研究已证实，将注意力机制引入到主流检测框架，可显著提升对PPE小目标的精度，为工地安全监控场景提供更可靠的技术支撑。

2.4 本章小结

本章系统阐述图像检测与目标识别领域的基础原理，介绍了卷积神经网络中卷积运算的数学原理、权值共享机制的设计思想、池化层的功能实现以及感受野的理论演化均属于关键结构。R-CNN代表的两阶段算法与SSD、YOLO系列代表的单阶段算法构成检测算法主流。此外还介绍了PPE目标检测应用中使用的注意力机制，通过强化特征提取过程中的空间注意力与通道注意力进行权重分配来提升检测精度。

3 基于C2HiLo-YOLO的工地PPE检测算法研究及部署

YOLOv11n检测速度确有优势，但在小目标检测方面漏检误检多发。分析YOLOv11n注意力机制后本文引入HiLo注意力来设计C2HiLo特征增强模块。C2HiLo模块嵌入YOLOv11n骨干网络，主要依靠高低频特征双支路提取与融合增强模型对小目标的特征表达能力。HiLo注意力捕获高频细节与低频语义特征，检测精度得以提升，YOLOv11n对小目标细节响应不足的缺陷获得弥补。

3.1 YOLOv11n模型选择依据及分析

工地PPE检测任务需要模型兼顾检测精度与推理速度。2024年问世的YOLOv11n属于轻量化架构，已获社区充分检验。YOLOv11n所采用的C3k2主干与C2PSA注意力模块[62]，在保持较低计算量的前提下，显著增强了YOLOv11n对小目标的特征提取能力。YOLOv11n被选作基础框架，与工地场景中PPE目标的具体分布特点直接相关。安全帽、反光背心等PPE在图像中占比普遍偏小，YOLOv11n借助多尺度特征融合机制有效降低了PPE小目标的漏检率。C2PSA模块通过位置敏感注意力机制强化了YOLOv11n对局部细节的空间感知，这一感知能力对提取PPE的纹理特征（如反光条纹）至关重要。正是C2PSA的空间注意力使得YOLOv11n能够更精准地捕捉PPE的细粒度纹理信息，相同条件下YOLOv11n的检测表现优于YOLOv8n，第四章实验数据对YOLOv11n在PPE检测任务中的优势给出了明确验证。轻量化设计使YOLOv11n在维持高检测精度的同时保障了推理速度，这一特性保证了YOLOv11n在工地动态场景下的部署可行性。

3.1.1 Backbone网络

Backbone网络包括Conv、C3k2、SPPF三部分[58]，这三部分共同承担特征提取任务。C3k2模块是特征提取的关键单元，借助Bottleneck残差瓶颈结构保证特征提取能力，同时控制计算量。该设计符合轻量化方向。作为跨阶段局部瓶颈结构，C3k2在计算效率上优于前代，放弃了YOLOv8中单个大卷积[55]，转而采用两个小卷积串联运算。

“k2”代表更小的卷积核尺寸，模型性能不受影响，处理速度反而提升。这一权衡在工程实践中尤为重要。

YOLOv11沿用前代版本的快速空间金字塔池化模块（Spatial Pyramid Pooling Fast, SPPF）。SPPF模块并行执行最大池化操作，聚合多尺度特征，捕获不同大小目标信息。输入图像经SPPF下采样后生成不同尺度的特征图，这些特征图被送至Neck和Head网络，为后续检测提供高质量基础。

原始YOLOv11n在Backbone末端引入C2PSA模块[62]（C2f and Pixel Spatial Attention）。C2PSA引入空间注意力机制，强化特征图对重要区域的聚焦能力。特征经空间池化处理后，模型准确锁定图像中的特定感兴趣区域。注意力机制动态调节像素权重，关键特征由此得到强化，特征提取的针对性显著提高。

3.1.2 Neck网络

Neck网络位于Backbone与检测头之间，职责是对Backbone输出的多尺度特征进行深度融合与增强，打通深层语义信息与浅层细节信息的传递链路，为后续目标检测预测提供高质量的特征输入。

YOLO11n采用PANet (Path Aggregation Network) 的优化变体结构[58]，借助自顶向下与自底向上的双向特征传递路径实现跨尺度特征的高效融合。自顶向下路径中上采样操作将高层强语义特征放大，与同尺度的浅层细节特征进行通道维度拼接，增强模型对小目标的感知能力。自底向上路径中卷积下采样操作将融合后的浅层特征压缩，再与同尺度的深层特征拼接，增强模型对大目标的定位能力。这种双向融合结构兼顾了不同尺度目标的检测需求，是提升模型整体检测精度的关键环节。

YOLO11n引入C3k2模块[63-64]用于精细化处理融合后特征，进一步强化特征表达能力。该模块分布在检测头多条路径，在不同深度处理多尺度特征。c3k参数控制其结构：取False时，C3k2模块退化为类似C2f的结构，采用标准瓶颈；取True时，瓶颈结构替换为C3模块，支持更深层、更复杂的特征提取。

C3k2模块的关键特性体现在两方面。处理速度上，相较单个大卷积，两个小卷积的设计降低了计算开销，实现更快速的特征提取。参数效率上，作为跨阶段局部瓶颈结构的紧凑版本，C3k2使整体架构在可训练参数量上更具优势。模型中新增的C3k模块支持自定义卷积核大小，灵活性更强，其自适应性能够更有效地从图像中提取精细特征，进而提升目标检测精度。

YOLOv11的检测头在C3k2模块之后集成多个CBS（卷积-批归一化-SiLU激活）层。这些层提取有效特征以实现精准目标检测，批归一化稳定并规范化数据流，SiLU激活函数引入非线性特性，三者共同提升模型性能。

3.1.3 Head网络

YOLO11n的检测头是最终预测模块。该检测头接收Neck网络输出的多尺度特征图，完成边界框坐标、类别标签与置信度得分的预测。在架构上，该检测头采用轻量化解耦头设计，将边界框回归任务与类别分类任务在网络结构上拆分处理。回归任务与分类任务各自独立。解耦设计避免了回归与分类之间的优化冲突，在轻量化前提下提升了检测精度与收敛速度。Neck网络输出的P3/8、P4/16、P5/32三组特征图构成特征金字塔，分别对应小目标、中目标与大目标三类检测需求。这些特征图被检测头接收后，各尺度分支通过独立的预测分支输出对应目标，预测分支的结果最终整合形成全图检测结果。

3.2 C2HiLo：基于高频和低频特征的注意力机制的改进模块

在复杂的PPE检测任务中，原始YOLO11n的检测头面对多尺度、高密度的PPE小目标时，性能瓶颈逐渐显现。施工现场光照复杂多变，脚手架背景杂乱无章，人员密集交错造成的严重遮挡进一步加剧了PPE小目标的检测难度。安全帽、防护眼镜或躯干上的反光条带等关键PPE小目标，在整幅图像中像素占比极低，属于典型的微弱特征。这直接制约了检测头对高频细节的提取能力。该检测头接收经Neck融合的多尺度特征图后，仍以常规卷积堆叠方式提取特征响应，无法有效将微小PPE小目标的边缘与纹理从庞杂背景杂波中剥离，致使PPE小目标的特征信噪比急剧下降。其特征表征极易被背景噪声湮没，密集场景下频繁发生漏检与误识别。

YOLO11n主干网络中的C2PSA模块原本用于强化空间感知，处理高分辨率特征图时暴露出固有缺陷。C2PSA的像素级空间注意力需计算特征图内所有空间位置之间的全局成对关联，这种密集计算造成了显存占用与计算负载的双重冗余，严重拖累轻量级模型原有的推理效率。该全局注意力机制在聚合空间上下文时，易被大面积低频背景（如大

楼轮廓、天空、地基）所主导，关键注意力权重难以精准聚焦于包含丰富高频细节的微小PPE小目标，抑制了模型对PPE小目标的检测辨识力。

原始网络在复杂背景下特征提取能力受限，C2PSA模块处理高分辨率特征时计算负担过重，细粒度小目标特征难以聚焦。本节注意力优化策略从频段特征解耦入手，利用HiLo注意力机制设计HiLoBlock计算单元。HiLoBlock借鉴跨阶段局部网络的梯度分流思路构建C2HiLo特征增强模块。C2HiLo模块捕获高频细节特征并兼顾低频语义表征，替换原网络中表现欠佳的注意力模块架构，重塑模型对工地场景关键特征的响应权重与特征激活模式。

3.2.1 HiLo注意力机制介绍

HiLo (High-Low) 注意力机制[65]将标准自注意力分解为高频局部注意力和低频全局注意力两个部分，图3.1展示了其结构示意图。高频分量对应图像的细节、边缘和局部纹理，低频分量对应图像的整体结构、语义和全局上下文，这是视觉任务中的常见划分。标准自注意力机制[61]试图用同一组参数同时捕获这两类信息，计算全局依赖时容易忽略局部细节，关注局部细节时可能丢失全局视野。HiLo使用频率分离解耦这两种特征的计算过程。设置比例参数后，模块将输入特征的注意力头划分为高、低两个分支。低频分支中，全局场景和语义结构变化通常较为平缓，模型采用设定了窗口大小的平均池化操作实现空域下采样，降低特征图空间分辨率，大幅减少键和值的特征计算量，以极低计算开销捕获全局依赖关系。高频分支在原始的高分辨率特征图上应用局部窗口自注意力，保留安全帽纹理、反光衣边缘等重要的细粒度特征，划分空间窗口限制注意力权重的计算范围，能够精准且高效地提取局部细节。两个分支的输出结果在通道维度拼接融合，结合了全局感受野和局部细节。

图3.1 HiLo注意力机制示意图

3.2.2 C2HiLo模块的设计与实现

在YOLO11n的原有架构中，尽管其主干采用的C2PSA模块在一定程度上增强了特征图的空间感知能力，但仍存在计算负担重且容易对复杂背景过度“关注”的问题，这极易掩盖或弱化本就微小的防护装备特征[62]。

为了构建专门针对工地PPE检测优化的特征增强算法，本研究在保留跨阶段局部网络设计理念的基础上，提出了C2HiLo（即融合HiLo注意力机制的C2结构）改进模块。在模块的具体设计中，C2HiLo借鉴了C2模块的高效分支结构：首先将输入特征通过卷积层进行降维映射，随后分离为两个并行的分支，一条浅层分支用于短接直连以保留网络的原生特征，而另一条深层分支则将标准的PSA模块替换为了HiLo模块。图3.2展示了HiLo块如何插入C2结构当中的示意图。

图3.2 C2HiLo模块示意图

在HiLoBlock中，二维HiLo注意力块被反复堆叠用于深层特征挖掘。高频分支借助局部窗口的表征能力捕获安全帽等目标的边缘细节，低频分支通过池化聚合维系人物躯干与施工环境的空间上下文。深层分支完成注意力权值重标定后，与起引导作用的直连分支重新对齐合并。该注意力设计对特征通道实施动态校准，滤除施工现场冗余背景的干扰，规避低维度注意力运算中的信息崩塌退化，为检测头输出紧致、鲁棒的高质量特征表征。

3.3 C2HiLo-YOLO模型整体结构与优势

以YOLOv11n为检测骨架，本研究将C2HiLo特征增强模块嵌入YOLOv11n，针对工地PPE检测的小目标、遮挡及复杂背景等痛点定向优化，构建了C2HiLo-YOLO轻量化模型。C2HiLo-YOLO保留了YOLOv11n核心架构、预训练权重迁移能力以及YOLOv11n的轻量化核心优势。在此基础之上，C2HiLo-YOLO定向提升了YOLOv11n针对小目标PPE、遮挡目标PPE

及复杂背景下PPE的检测性能。C2HiLo-YOLO模型完美契合了工地PPE实时监测对工程化边缘部署的需求。图3.3给出了C2HiLo-YOLO的整体结构。

3.3.1 C2HiLo-YOLO模型整体结构设计

C2HiLo-YOLO保留了YOLOv11n原生的Backbone-Neck-Head三层架构，继续使用性能稳定的C3k2特征提取模块、SPPF多尺度池化模块、C2PSA初步空间注意力模块以及PANet双向多尺度特征融合结构，从而较好地继承了原模型轻量、高推理速度与基础特征提取能力等核心优势。在此基础上，本研究未对主干网络进行大规模改动，而是采用“颈层末端定向增强”的轻量化改进策略，将C2HiLo模块集成至网络颈层（Neck）向检测头（Head）过渡的末端连接处。其具体结构设计与数据流如下：

图3.3 C2HiLo-YOLO总体模型结构示意图

输入图像进入Backbone主干网络后，经Conv卷积层与C3k2模块完成8倍、16倍、32倍连续下采样。下采样后的特征图通过SPPF模块进行多尺度全局特征聚合，再经C2PSA模块完成初步空间注意力增强。主干网络最终输出3组不同尺度的基础特征图。这些基础特征图进入Neck网络后，利用PANet结构的自顶向下上采样与自底向上下采样双向路径，实现深层语义信息与浅层细节信息的跨尺度融合。融合后的特征生成P3、P4、P5三组高质量特征图，分别对应8倍、16倍、32倍下采样尺度。这三组特征图分别适配小、中、大三类目标的检测需求。

本研究在P4和P5两个尺度的特征层后引入C2HiLo特征强化模块，该模块位于特征进入检测头前的关键节点，输入输出通道数与原特征层对齐，无需修改检测头网络结构。P3层是浅层高分辨率特征，主要承载图像的边缘与纹理信息，语义信息较弱且背景噪声占比较高。直接接入注意力模块会引入大量无效计算，故将其直接输入检测头的小目标预测分支。P4和P5层是深层融合特征，经Neck双向特征融合后已完成浅层细节与深层语义的初步对齐，是输入检测头前的最后一组特征——其特征质量直接决定最终检测精度。工地场景中遮挡、密集和重叠的PPE目标，其有效特征极易在这两层中被低频背景信息淹没。在这两层后接入C2HiLo模块，相当于在特征进入检测头前完成一次筛选与强化。

P4和P5层的融合特征先经过C2HiLo模块完成高低频特征解耦与重加权，其中高频分支强化PPE目标的细粒度特征，低频分支过滤冗余背景干扰并保留全局上下文信息。提纯后的特征分别输入检测头的中目标与大目标预测分支。检测头的三个独立解耦分支分别完成对应尺度目标的边界框回归、类别分类与置信度预测，整合后输出全图检测结果。C2HiLo模块保留了原C2结构的shortcut短接分支，与HiLoBlock的深度处理分支形成梯度分流，既保证了新增模块的训练收敛性，又未破坏原模型的特征传递链路。这一设计可兼容YOLOv11n的预训练权重，降低了模型的训练成本。

3.3.2 C2HiLo-YOLO模型的核心结构优势

相比于原版YOLOv11n模型，C2HiLo-YOLO并非简单的网络结构堆叠与参数增加，而是针对工地PPE检测的核心痛点进行了定向优化，展现出三大不可替代的结构优势，彻底解决了轻量化检测模型长期存在的技术瓶颈。

第一，C2HiLo-YOLO通过高低频注意力机制的参数解耦，实现了检测注意力的定向精准分配，从根本上改善了工地复杂场景下的漏检与误检问题。原生YOLOv11n的C2PSA模块采用全局像素级注意力，在处理工地场景时，权重易被大面积低频背景主导，形成“大水漫灌”式的分配局面，导致占比极小的PPE目标（安全帽、反光条、护目镜）的高频细节特征被淹没，在人员密集重叠、目标被遮挡、光照不均的极端工况下，漏检与误检问题频发。

而C2HiLo-YOLO将高低频注意力机制的参数解耦，使用HiLo注意力机制将特征的高频分量与低频分量完全解耦，双分支独立计算、各司其职。高频分支采用局部窗口自注意力，在高分辨率特征图上不受全局背景干扰，精准捕捉PPE目标的边缘、纹理、反光条纹等关键细粒度特征；低频分支则对下采样后的低分辨率特征图施加全局注意力，以极低的计算开销捕获场景全局上下文信息，明确目标与环境的空间关系，避免背景误检。这种“全局语义兜底”与“局部细节聚焦”的双分支设计，使网络的注意力资源从全局平均分配转变为定向倾斜，将核心计算资源集中于承载关键检测信息的高频特征波段。这一设计从根本上解决了原生模型对小目标、遮挡目标特征响应不足的问题。在工地场景的实际检测中，未佩戴安全帽、未穿反光背心等违规目标的漏检率大幅降低，背景杂物的误检情况也得到显著减少，检测结果的可靠性随之提升。

第二，C2HiLo-YOLO采用轻量化模块设计，检测精度与推理速度均表现良好，适合边缘端实时部署。传统的注意力改进方案如全局自注意力等传统注意力改进方案能提升检测精度，但计算量与参数量呈平方级增长，模型规模膨胀、推理速度下降，难以满足工地场景下边缘计算盒子、智能监控摄像头等低算力设备的实时检测需求。多数高精度检测模型难以工程落地，症结正在于此。

C2HiLo-YOLO引入的C2HiLo模块通过两项核心设计严格控制模型规模与计算开销。低频分支使用平均池化下采样降低特征图空间分辨率，将全局注意力的计算复杂度从 $O(n^2)$ 降至 $O((n/r)^2)$ （ r 为下采样倍率），显存占用与浮点运算量显著减少。高频分支使用局部窗口自注意力，注意力计算限制在独立窗口内，避免全局像素成对计算，进一步压缩计算开销。实际性能上，C2HiLo-YOLO参数量2.9M，较原生YOLOv11n的2.6M仅增加0.3M，计算量从6.3GFLOPs升至6.8GFLOPs，远低于YOLOv11m、YOLOv8m等中型模型。单张640×640图像推理时间6.8ms，较原生YOLOv11n仅增加0.4ms，满足工地监控视频流25fps的实时检测需求。C2HiLo模块的轻量性使得精度提升的同时推理速度基本未受影响。

第三，C2HiLo-YOLO采用高低频解耦的双分支设计，在同一模块内同时实现了全局大感受野与局部高细节捕捉，打破了传统轻量化前馈网络在感受野与细节捕捉之间难以兼顾的固有壁垒。在轻量化检测模型的常规设计中，扩大感受野以捕获全局上下文，与聚焦局部细节以提取小目标细粒度特征，始终存在不可调和的矛盾：扩大感受野会因下采样丢失细节信息，聚焦局部细节则会损失全局上下文，导致模型极易出现“大目标检测准、小目标漏检多”或“细节抓得住、背景误检多”的问题。

C2HiLo-YOLO的低频分支则侧重建立全局空间关系，提供完整的场景语义支撑；高频分支则专注于挖掘局部细粒度特征，精准锁定小目标的关键信号。两条分支在通道维度拼接融合后，输出的特征图兼具强语义与细细节。这一设计使模型在边缘端低算力部署场景下，同时具备优异的小目标检测能力与全局场景鲁棒性，可自适应应对工地中不同距离、不同尺度、不同遮挡程度的PPE目标检测需求。

综上，C2HiLo-YOLO模型通过定向的结构优化，在保留原生YOLOv11n轻量化、高实时性核心优势的基础上，针对性解决了工地PPE检测场景下的核心痛点，为施工场景的实时安全监测提供了一套高性能、易部署的轻量化检测方案，其具体性能表现将在第四章的实验中系统进行验证与分析。

3.4 系统部署和实施

为验证施工现场个人防护装备识别系统的可用性，我们在本地Linux环境下完成系统部署，并使用训练后的PPE检测模型构建了一个可交互的演示技术原型。该演示原型采用“模型推理服务”加“前端展示界面”的部署架构，

整个推理流程包括模型加载、图像输入、目标检测和结果可视化。整体部署流程可划分为模型导出、环境配置、服务启动和功能验证四个阶段。

PPE检测模型被导出为ONNX计算图。相比直接依赖训练框架权重文件，ONNX计算图的跨平台兼容性更好，后续在不同推理后端和硬件设备上复用更加方便。系统部署时默认加载导出的ONNX模型文件，通过统一的ONNX Runtime推理接口完成目标检测，降低了对训练代码运行环境的依赖，也提升了部署灵活性。

运行环境配置在Linux平台上，需要Python 3.9及以上版本和一系列推理与服务依赖库，包括Ultralytics、FastAPI、Uvicorn、Pillow、NumPy和ONNX Runtime。硬件配置方面，若部署设备配有NVIDIA GPU，可通过ONNX Runtime GPU版本调用CUDA加速；没有独立显卡时，也可切换为CPU模式运行。依赖安装完成后，设置好模型路径和设备参数即可启动后端推理服务。整个部署过程简单，适合展示及中小规模实验验证。

该平台后端使用FastAPI构建轻量化推理接口，前端以静态网页实现图像上传、参数调整与结果展示。服务启动后自动加载ONNX模型。该模型对外提供健康检查接口与图像推理接口，用户通过浏览器访问前端页面后可上传待检测图片并设置置信度阈值等参数，调用后端完成推理。后端将图像缩放归一化后调用ONNX Runtime执行前向推理，对检测框后处理并绘制结果，将带标注的图片返回前端展示。安装项目依赖并准备好导出的ONNX模型文件后通过Uvicorn启动FastAPI服务。浏览器访问本地页面上传测试图像进行推理，观察系统返回的检测结果，含安全帽、反光衣、手套等类别的识别框及置信度信息。视频流测试时使用MediaMTX启动本地RTSP服务，ffmpeg推送MP4文件为RTSP流后调用命令行推理脚本对该流进行检测。

图3.4 系统部署前端页面推理示范

3.5 本章小结

本章围绕轻量化YOLO模型在工地PPE检测场景中面临三重困境：小目标特征捕获的天然弱势、复杂背景条件诱发的高漏检率与误检率、全局注意力机制的计算冗余严重制约精度与实时性的平衡。选定YOLOv11n作为基础架构后，本文系统剖析其结构优势并识别其在工地特定场景中的适应性缺陷。基于此分析，本文提出C2HiLo轻量级特征增强模块。该模块借助HiLo高低频特征解耦注意力机制在模型中引入对背景噪声的有效抑制。C2HiLo在保留高分辨率细节信号的同时控制计算资源消耗，达成PPE检测精度与边缘端推理效率的均衡。将C2HiLo模块嵌入原始Head网络的P4、P5深层特征层，构建出完整的C2HiLo-YOLO改进模型。理论分析证实，C2HiLo-YOLO能够在复杂场景条件下同步优化小目标PPE的检测准确度与边缘端推理速率。

4 C2HiLo-YOLO检测算法实验验证

本章围绕本文提出的C2HiLo-YOLO检测算法展开实验验证。为全面评估该方法在施工场景个体防护装备检测任务中的有效性，本文选取Construction-PPE和DPPE两个公开数据集作为实验对象，并与RT-DETR-L、YOLOv11m、YOLOv11n、YOLOv8m、YOLOv8n、YOLOv5m和YOLOv5n等主流检测模型进行对比。实验从检测精度、召回能力、综合平均精度、推理速度以及模型复杂度等多个维度进行分析，以验证所提方法在精度和轻量化方面的综合优势。

4.1 数据集

为保证实验结论具有充分的代表性，本文选取了两个与施工安全监测密切相关的PPE检测数据集。两个数据集在类别设置、场景构成和任务侧重点上具有一定差异，能够较为全面地检验模型的泛化能力与适用性。

4.1.1 Construction-PPE数据集

Construction-PPE数据集[66]是一个专门面向建筑工地的个体防护装备检测与安全合规审查任务。该数据集由Ultralytics公司发布，所有样本均采集自真实施工环境。光照条件、拍摄视角、人员姿态及装备遮挡情况各不相同。样本中既有工人按要求佩戴安全帽、手套、反光衣、防护靴和护目镜的合规场景，也有缺失部分或全部防护装备的违规场景。这种“合规与违规并存”的构成，使该Construction-PPE数据集能同时支撑两项核心任务，既可以精准检测各类PPE，也可以用于识别作业人员具体缺少哪类防护装备，为自动化安全巡检提供数据基础。

Construction-PPE数据集包含1416张标注图像，按训练集、验证集和测试集划分，数量分别为1132张、143张和141张。所有标注均采用Ultralytics YOLO格式，可直接对接YOLO等主流目标检测框架，便于工程部署。数据集共设11个类别，包括已佩戴装备（helmet、gloves、vest、boots、goggles）、人员基类Person，以及缺失装备类别（no_helmet、no_goggle、no_gloves、no_boots）。与仅标注“存在某物体”的常规目标检测数据集不同，该数据集采用“已佩戴”与“缺失装备”双重标注机制，使模型不仅能识别工人是否穿戴防护用具，还能直接定位具体缺少哪类装备的违规目标，从而提升了在施工现场安全自动巡检、违规行为实时告警等场景中的工程部署价值。

4.3.1 Dataset of Personal Protective Equipment数据集

DPPE (Dataset of Personal Protective Equipment) [67]是由Mendeley Data平台公开发布的一个专门面向个体防护装备检测的数据集。该数据集共采集了2286张图像，每张图像的分辨率统一为640×640像素，样本来源非常广泛，既包括从GitHub、Kaggle、Roboflow等公开平台获取的开源图像，也包含从真实施工或作业场景中拍摄的实景图片。这种多样化的数据来源使得DPPE能够覆盖不同设备、不同环境条件以及不同作业场景下的人员姿态与装备呈现方式，具有较强的场景泛化能力。在标注格式方面，DPPE严格遵循YOLO系列的训练规范（即每个目标以“类别索引x_center y_center width height”的形式进行归一化标注），这一特性使得该数据集无需额外格式转换即可直接接入YOLOv5、YOLOv8等主流目标检测框架进行模型训练与验证。

本文实验采用的数据配置下，DPPE划归四个类别：Helmet（已佩戴安全帽）、NoHelmet（未佩戴安全帽）、Vest（已穿戴反光衣）、NoVest（未穿戴反光衣）。相比Construction-PPE数据集涵盖的更多类别，DPPE的分类聚焦与前者不同，DPPE仅针对安全帽与反光背心两类装备，每种装备标注已佩戴与缺失两种状态。DPPE类别的精简规避了多类别样本不均衡对训练造成的干扰。DPPE的类别聚焦特性使其适用于分析目标检测模型在核心PPE类别上的识别稳定性，简明的分类粒度便于评估模型在边界清晰、结构简单的条件下所展现的特征学习能力与泛化效能，为比较不同数据集构成对模型性能的影响提供了有价值的参照。

4.2 实验设置

为保证实验公平可比，所有参与对比的模型均使用对应预训练权重完成初始化，在严格一致的实验环境下训练验证。各模型统一设定训练轮数50，输入图像尺寸640×640，批量大小8，数据加载线程数4，初始学习率0.01，早停参数patience设为20，随机种子固定为0。YOLO系列模型训练过程统一采用close_mosaic=10的配置，减弱后期过强数据增广对模型收敛稳定性的干扰。统一配置避免了训练策略差异干扰结果，模型结构本身的性能差异得以直接呈现。实验所使用的硬件环境为：Intel Xeon Gold 6248R CPU，NVIDIA A800 GPU，64 GB RAM，Ubuntu 20.04操作系统。

C2HiLo-YOLO改进自YOLOv11n。主干网络保持不变，检测头的中高层特征融合位置引入C2HiLo模块，HiLo注意力替代部分原有特征交互单元，增强模型对多尺度目标（中小尺度PPE目标）的特征建模能力。改进模型专门配置了适

应PPE检测任务的训练超参数：SGD优化器、动量0.937、权重衰减0.0005、预热训练3个epoch、针对检测任务调节的box、cls与dfl损失权重。配置后，模型在施工安全场景下的收敛稳定性与检测稳健性均有提升。

4.3 实验评价指标

为了全面衡量模型性能，本文选取Precision、Recall、mAP50、mAP50-95、推理时间、参数量和计算量作为评价指标，从检测精度、检出能力、综合性能和部署成本四个方面对模型进行评估。

Precision表示在所有被模型判定为正样本的检测结果中，真实为正样本的比例，其计算公式为：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (4.1)$$

其中，TP表示真正例数量，FP表示假正例数量。Precision越高，说明模型误检越少，检测结果越准确。

Recall表示在所有真实目标中，被模型成功检测出的比例，其计算公式为：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (4.2)$$

其中，FN表示假负例数量。Recall越高，说明模型漏检越少，对目标的覆盖能力越强。在施工安全监测场景中，漏检未佩戴防护装备的人员可能带来较大风险，因此Recall具有较强的实际意义。

mAP是目标检测任务中最常用的综合评价指标，其计算公式如下：

$$\text{AP} = \int_0^1 P(R) dR \quad (4.3)$$

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N \text{AP}_i \quad (4.4)$$

其中， $P(R)$ 表示在某一召回率 R 下的精确率，公式(4.3)通过对精确率-召回率曲线积分，计算单个类别的平均精度（AP）； N 表示类别总数，公式(4.4)对所有类别的AP取平均，得到均值平均精度（mAP），用于综合衡量模型在所有类别上的检测性能。

物理意义上看，AP指单类别在不同召回率下精确率曲线所围成的面积，mAP为所有类别AP的平均值。本文选取mAP50和mAP50-95作为评价指标。mAP50是IoU阈值为0.5时的平均精度，直观反映模型的整体检测能力；mAP50-95则在IoU从0.5到0.95、步长0.05的多个阈值下取平均值，评价标准更为严格，能更充分反映模型对目标定位精度和检测稳定性的综合表现。通常，mAP50更适合衡量模型的检出能力，mAP50-95则更能体现模型在高质量检测任务中的综合水平。

但在工地PPE小目标检测场景中，小目标的边界偏差对IoU数值影响显著。漏检未佩戴安全帽的工人直接构成安全事故隐患，而预测框的轻微偏移在分类正确的前提下不影响安全告警的业务闭环。因此将mAP50作为核心评价指标，以精准衡量模型的检出能力，匹配工地安全检测对低漏检的核心需求；mAP50-95因对定位精度要求严苛，仅作为模型综合性能的辅助参考。

除检测精度外，推理时间、参数量、计算量也被纳入统计。推理时间衡量模型处理单张图像所需的平均时长，直接决定其能否满足实时性要求。参数量刻画模型规模，数值越小越容易部署至边缘设备。计算量以GFLOP为单位，

反映一次前向推理所需的浮点运算次数，用于评估模型复杂度与硬件开销。施工现场实时监控这类应用场景中，模型不仅需要具备较高的检测精度，还应兼顾较低参数规模和较快的推理速度。因此，本文将上述指标进行联合分析。

4.4 实验结果

4.4.1 Construction-PPE数据集结果

在Construction-PPE数据集上的实验结果如表4-1所示。总体来看，本文提出的 C2HiLo-YOLO在该数据集上取得了最佳的mAP50指标，其数值达到0.634，优于所有对比模型。与原始YOLOv11n相比，mAP50从0.599提升至0.634，提升了0.036；与性能较强的YOLOv11m相比，也提升了0.019。该结果表明，在复杂施工场景下，C2HiLo模块能够有效增强模型对PPE目标的判别能力。

表4.1 在Construction-PPE数据集上的实验对比结果

	Precision	Recall	mAP50	mAP50-95	推理时间 (ms)	参数量 (M)	计 算 量 (GFLOP)
rtdetr-l	0.562	0.653	0.607	0.303	9.7	32.0	103.5
yolov11m	0.653	0.583	0.615	0.308	8.0	20.0	67.7
yolov11n	0.576	0.581	0.599	0.300	6.4	2.6	6.3
yolov5m	0.543	0.591	0.579	0.296	7.5	25.0	64.0
yolov5n	0.648	0.538	0.572	0.278	5.5	2.5	7.1
yolov8m	0.680	0.568	0.577	0.289	7.9	2.6	78.7
yolov8n	0.703	0.551	0.584	0.288	5.5	3.0	8.1
C2HiLo-YOLO	0.621	0.602	0.634	0.295	6.8	2.9	6.8

从Precision和Recall指标来看，C2HiLo-YOLO分别达到0.621和0.602。相比原始YOLOv11n，Precision提升了0.046，Recall提升了0.022，说明改进后的模型不仅在误检控制方面表现更好，同时也提高了对真实目标的检出能力。对于Construction-PPE这种同时包含正样本与缺失装备负样本的复杂数据集而言，这种更均衡的精度与召回表现具有较高价值。

C2HiLo-YOLO的Precision达到0.621，Recall达到0.602。相比原始YOLOv11n，C2HiLo-YOLO的Precision提升了0.046，C2HiLo-YOLO的Recall提升了0.022。C2HiLo-YOLO的Precision和Recall提升说明其对真实目标的检出能力和误检控制上的表现都比原本的YOLOv11n更优。对于Construction-PPE这类正样本与缺失装备负样本并存的复杂数据集，C2HiLo-YOLO在Precision与Recall之间这种更均衡的表现具有较高实用价值。

在mAP50-95这一更严苛的评测基准下，C2HiLo-YOLO的mAP50-95得分为0.295，较YOLOv11m的0.308和RT-DETR-L的0.303略低，但差距较小。从模型复杂度角度分析，C2HiLo-YOLO的参数量仅2.9M、计算量仅6.8GFLOPs，这两项资源开销大幅低于YOLOv11m的20M参数量与67.7GFLOPs计算量，也显著低于RT-DETR-L的32M参数量和103.5GFLOPs计算量。C2HiLo-YOLO在更高定位精度要求下虽非绝对最优，但凭借极低的模型代价，同时取得了最优的mAP50和较强的

综合检测能力，体现出优异的精度效率比。C2HiLo-YOLO以极低的资源开销换来了突出的精度效率比。

在推理速度方面，C2HiLo-YOLO的单张图像推理时间为6.8ms，仅比YOLOv11n增加了0.4ms，但显著优于多数中大型模型的综合开销。说明所引入的C2HiLo模块并未明显破坏原有轻量模型的实时性，而是在较小额外代价下换取了更好的检测性能。综合来看，C2HiLo-YOLO在Construction-PPE数据集上表现出良好的精度与实时性平衡能力，适合应用于施工场景的在线安全监测任务。

4.4.2 Dataset of Personal Protective Equipment数据集结果

表4.2 在Dataset of Personal Protective Equipment数据集上的实验对比结果

	Precision	Recall	mAP50	mAP50-95	推理时间 (ms)	参数量 (M)	计 算 量 (GFLOP)
rt detr-l	0.592	0.739	0.706	0.504	6.8	32.0	103.5
yolov11m	0.643	0.681	0.725	0.522	5.6	20.0	67.7
yolov11n	0.656	0.653	0.707	0.503	4.5	2.6	6.3
yolov5m	0.609	0.734	0.715	0.512	5.4	25.0	64.0
yolov5n	0.576	0.771	0.710	0.508	3.7	2.5	7.1
yolov8m	0.586	0.751	0.710	0.512	3.7	2.6	8.1
yolov8n	0.620	0.699	0.715	0.512	5.4	3.0	78.7
C2HiLo-YOLO	0.626	0.719	0.719	0.504	5.2	2.9	6.8

在DPPE数据集上的实验结果如表4-2所示。与Construction-PPE数据集相比，DPPE的类别体系更为集中，因此更能反映模型在关键PPE类别上的识别能力。从实验结果可以看出，C2HiLo-YOLO在DPPE数据集上的mAP50达到0.719，位列所有模型中的第二位，仅略低于YOLOv11m的0.725，但明显优于YOLOv11n、YOLOv5n、YOLOv8n和RT-DETR-L等其他模型。虽然位列第二位，但是比YOLOv11m轻量得多，这说明本文方法在不同PPE检测数据集上均具有较好的稳定性和迁移能力

与原始YOLOv11n相比，C2HiLo-YOLO的Recall从0.653提升至0.719，提升幅度达到0.066，表明改进模型对真实目标的覆盖能力有明显增强。对于PPE合规检测任务而言，较高的召回率意味着模型更不容易漏检未佩戴安全帽或未穿反光背心的人员，因此在实际安全监管场景中更具实用意义。与此同时，模型的mAP50-95达到0.504，与YOLOv11n的0.503基本持平，说明模型在提升目标检出能力的同时，并未明显牺牲定位质量。

C2HiLo-YOLO在该数据集上的Precision为0.626，低于YOLOv11n的0.656和YOLOv11m的0.643。C2HiLo-YOLO在提升Recall的同时，也引入了误检的增加。在PPE施工场景中，漏检带来的风险通常高于少量虚警，因此C2HiLo-YOLO在Precision与Recall之间的取舍具有合理性。施工安全预警系统尤其需要更高的Recall，以降低安全违规目标的漏报概率。

从复杂度指标来看，C2HiLo-YOLO的参数量为2.9M，计算量为6.7GFLOPs，推理时间为5.2ms，仍保持较好的轻量化特征。相较于YOLOv11m、YOLOv5m和YOLOv8m等中型模型，其规模显著更小，但性能已接近甚至超过多数对比方

法。这说明所提出的改进策略能够在较低模型成本下有效提升检测能力，具有较好的部署潜力。

4.4.3 消融实验

为进一步验证本文所提出C2HiLo模块的有效性，并分析各组成部分对检测性能的具体影响，本文以YOLO11n为基线模型，在相同训练策略和实验环境下，在Construction-PPE数据集上开展消融实验。消融实验共设置4组方案，分别为：原始YOLO11n基线模型、仅引入C2结构的方法（无注意力）、在C2结构基础上引入Transformer注意力的C2方法，以及本文提出的C2HiLo-YOLO。各方案实验结果如表4.3所示。

表4.3 在Construction-PPE数据集上的消融实验结果

	Precision	Recall	mAP50	mAP50-95
YOLO11n基线	0.576	0.581	0.599	0.300
YOLO11n+C2	0.698	0.530	0.571	0.288
YOLO11n+C2+Transformer	0.625	0.578	0.596	0.294
C2HiLo-YOLO	0.621	0.602	0.634	0.295

表中数据揭示，基线模型引入C2结构后，查准率（Precision）从0.576跃升至0.698。模型预测趋于保守，误报数量下降。然而，该方案的查全率（Recall）滑落至0.530，mAP50同步跌至0.571。这表明单纯堆叠C2结构虽抬升了预测置信度，却折损了模型对目标的检出能力，漏检问题加剧。仅凭无注意力机制的局部特征重构，难以有效提升PPE检测任务的综合性能。

在C2结构基础上进一步引入一般Transformer后，模型Precision、Recall和mAP50分别达到0.625、0.578和0.596。与只引入C2相比，该方案在Recall和mAP50上均有明显回升，说明注意力机制的引入有助于增强特征表达能力，改善模型对目标区域的关注效果。但相较于基线模型，其mAP50仍略低于0.599，mAP50-95也由0.300下降至0.294，表明一般Transformer虽然在一定程度上缓解了C2带来的性能下降，但在当前PPE检测任务中并未带来显著增益。

相比之下，本文提出的C2HiLo-YOLO取得了最优的综合效果。该方案的mAP50达到0.634，较基线模型提升了0.036；Recall达到0.602458，较基线模型提升了0.022；Precision也提升至0.621110。虽然其mAP50-95为0.295，略低于基线模型的0.300，但整体差距较小，而在更能反映检出能力的mAP50指标上实现了明显提升。这说明C2HiLo模块能够在保持较高检测精度的同时，增强模型对目标的召回能力，从而取得更优的综合检测效果。

进一步对比可以发现，C2HiLo-YOLO相较于Transformer方案，在Precision上略有下降，但Recall从0.578提升至0.602，mAP50从0.596提升至0.634，提升幅度分别达到0.024和0.038。这表明HiLo注意力相较于一般Transformer更适合本文的PPE检测任务，能够更有效地处理施工场景中多尺度目标、遮挡目标以及小目标的特征建模问题。其原因在于，HiLo机制通过高频局部建模与低频全局信息交互的结合，能够在较低计算代价下兼顾局部细节与全局上下文，从而更好地适应PPE目标尺寸小、类别分布不均和场景复杂的特点。

综合上述实验结果可以得出以下结论：第一，仅引入C2结构并不能提升模型的整体检测性能，反而会在一定程度上降低召回率和mAP，说明结构堆叠本身不是性能提升的主要来源；第二，引入一般Transformer注意力后，模型

性能较C2有所恢复，但相较基线仍无明显优势，说明常规注意力机制对该任务的适应性有限；第三，本文提出的C2HiLo模块能够在基线模型基础上取得最优综合表现，证明其在PPE检测任务中具有更好的特征提取与信息融合能力。因此，本文方法的性能提升主要来源于HiLo注意力与C2结构的有效结合，而非单纯的网络结构加深或参数增加。

4.5 C2HiLo-YOLO模型可视化分析

为进一步直观验证C2HiLo-YOLO模型在工地 PPE 检测任务中的性能优势与改进有效性，本节从模型收敛特性、类别区分能力、复杂场景检测效果三个维度，基于Construction-PPE数据集的实验结果开展系统性可视化分析，全面揭示C2HiLo改进模块对模型检测能力的提升机理。

4.5.1 模型收敛性分析

模型的收敛速度与平稳性是衡量其特征学习效率、工程部署适配性的核心指标，直接决定了模型在实际场景中的训练成本与落地可行性。图 4.4 为 C2HiLo-YOLO 模型在Construction-PPE数据集上训练过程的损失函数与核心评价指标变化曲线，其中蓝色实线为每轮训练的原始结果，橙色虚线为平滑拟合曲线，横轴为训练轮次（epoch）。

从训练损失曲线可以看出，C2HiLo-YOLO模型的边界框回归损失（train/box_loss）、分类损失（train/cls_loss）与分布焦点损失（train/dfl_loss）均在训练前期呈现极快的下降趋势，在20个epoch内便完成了损失值的主要下降过程，全程无剧烈震荡、梯度爆炸或损失反弹现象，平滑曲线与原始结果曲线贴合度极高。相较于原始YOLOv11n基线模型，改进后的模型通过HiLo高低频解耦注意力机制，能够引导网络快速聚焦于 PPE 目标的核心细粒度特征，避免了无效背景特征的冗余学习，大幅加快了模型的收敛速度，同时显著提升了训练过程的平稳性。

图4.1 C2HiLo-YOLO模型训练损失曲线

在验证集损失曲线中，模型的各项验证损失与训练损失保持了高度一致的下降趋势，在训练后期（40~50epoch）损失值稳定收敛至区间下限，未出现过拟合导致的验证损失抬升现象，证明C2HiLo模块的引入并未破坏模型的泛化能力，反而通过全局上下文与局部细节的协同建模，增强了模型对未知施工场景的适配能力。

从核心评价指标曲线来看，模型的精确率（Precision）、召回率（Recall）、mAP50 与mAP50-95均随训练轮次增加持续稳步上升，无明显的波动停滞阶段。其中反映核心检出能力的mAP50指标，在20个epoch时便达到0.55以上，最终稳定收敛至0.634，相较于原始YOLOv11n模型，不仅收敛速度提升显著，且最终收敛精度更高。上述结果充分证明，C2HiLo模块有效解决了原始模型在复杂工地场景下特征学习效率低、收敛不稳定的问题，实现了收敛速度、收敛稳定性与检测精度的同步提升。

4.5.2 类别识别混淆矩阵分析

为量化分析 C2HiLo-YOLO 模型对不同PPE类别的识别能力，尤其是对合规佩戴与违规未佩戴类别的区分效果，本节基于Construction-PPE数据集的测试结果，绘制模型的归一化混淆矩阵，如图4.2所示。矩阵横轴为真实标签，纵轴为模型预测标签，对角线数值代表对应类别的召回率，数值越接近1表明模型对该类别的识别准确率越高，非对角线数值代表类别间的误分类概率。

图4.2 C2HiLo-YOLO正则化后的类别识别混淆矩阵

从整体结果来看，C2HiLo-YOLO模型对施工场景核心目标均保持了极高的识别精度，其中Person类别的召回率达到0.84，安全帽（helmet）类别召回率0.83，反光背心（vest）类别召回率0.81，表明模型能够在复杂背景中精准

定位施工人员主体与核心防护装备，为后续PPE合规性判断奠定了坚实的基础。同时，模型对手套（gloves）、安全鞋（boots）、护目镜（goggles）等小尺寸、细粒度目标的召回率均达到0.70以上，类别间的误分类率普遍低于0.03，仅存在少量将目标误识别为背景的情况，充分验证了C2HiLo模块对小目标特征的增强提取能力。

针对工地安全监管中最核心的违规未佩戴类别，模型展现出显著优化的类别区分能力，有效解决了该类难样本的误识别问题。其中未佩戴安全帽（no_helmet）类别召回率达到0.36，未佩戴安全鞋（no_boots）类别召回率0.50，未佩戴手套（no_gloves）、未佩戴护目镜（no_goggle）类别也均实现了稳定检出。未佩戴类别普遍存在特征微弱、与背景相似度高、易与对应佩戴类别混淆的检测难点。

C2HiLo模块通过高频局部注意力分支，精准捕捉未佩戴状态下的目标边缘、纹理等细粒度特征，同时通过低频全局注意力分支建立目标与人员主体、施工场景的上下文关联，极大降低了佩戴与未佩戴类别之间的误分类概率——例如helmet与no_helmet类别之间的误分类率仅为0.01，从根本上提升了模型对违规行为的识别能力，完全契合工地安全监管中对违规行为精准检出的核心需求。

4.5.3 检测结果定性可视化分析

为直观展现C2HiLo-YOLO 模型在真实工地复杂场景下的检测性能，本节选取 Construction-PPE测试集中包含小目标、目标遮挡、密集人员、复杂背景干扰的典型样本进行定性可视化分析，检测框上标注了目标类别与预测置信度。




图4.3 C2HiLo-YOLO定性可视化分析

从可视化结果可以看出，C2HiLo-YOLO模型在各类极端施工场景中均展现出优异的检测性能，有效解决了原始YOLOv11n模型漏检、误检频发的痛点问题。从定性可视化结果来看，C2HiLo-YOLO模型在真实工地复杂施工场景中展现出优异的综合检测性能，有效解决了原始YOLOv11n模型在极端场景下漏检、误检频发的痛点问题，针对远距离拍摄下像素占比极小的安全帽、反光背心、护目镜等PPE小目标，模型实现了精准检出且无明显漏检，光伏施工、井下作业等典型场景中核心目标检测置信度普遍达0.8以上，这得益于HiLo注意力机制的高频分支，可在高分辨率特征图中保留并强化小目标的边缘、纹理等细粒度特征，从根本上解决了原始模型小目标特征淹没、漏检率高的核心问题。

在人员密集、肢体与装备相互遮挡的复杂场景中，模型仍保持优异的检测稳定性，多人遮挡的室内场景可精准识别防护装备佩戴或未佩戴的合规与违规目标，多人协同作业场景可完整检出重叠人员的防护装备，无漏检与重复检测问题，C2HiLo模块通过低频全局注意力分支建立目标间的上下文关联，结合高频分支对局部遮挡区域的特征补全，有效缓解了遮挡导致的特征缺失，大幅降低了密集遮挡场景的漏检与误检概率。

面对脚手架、施工设备、复杂光照等强背景干扰的工地场景，模型还展现出极强的抗干扰能力与多类别同步识别能力，可同时完成人员、多类防护装备佩戴或未佩戴状态的精准检测，仅存在极少量置信度低于0.5的误检结果，可通过置信度阈值有效剔除。

相较于原始模型，C2HiLo-YOLO通过高低频特征解耦，有效过滤了大面积低频背景的冗余干扰，将注意力资源精准聚焦于高频PPE目标区域，显著降低了复杂背景下的误检现象，完全满足施工现场实时安全监测的工程应用需求。

4.6 本章小节

本章基于Construction-PPE和DPPE两个公开数据集，对本文提出的C2HiLo-YOLO检测算法进行了系统实验验证，包括对比试验、消融实验和可视化分析。实验和分析结果表明，本文所提出C2HiLo-YOLO方法在保持轻量化特征的同时，能够有效提升YOLOv11n在PPE检测任务中的综合性能。其中，在Construction-PPE数据集上，C2HiLo-YOLO获得了最高的mAP50，超越了多个参数量比自身大得多的模型；在DPPE数据集上，其检测结果也接近最优，仅弱于YOLOv11m模型，但模型轻量化方面展现出明显的独特优势（YOLOv11m模型的参数两和推理时间为C2HiLo-YOLO的数倍）。综合精度、速度和复杂度分析可以说明，本文提出的改进方法平衡了性能和工程开销的考量，具备较好的工程实用性，为施工场景下的实时PPE智能检测提供了一种有效方案。

结 论

建筑行业的高风险性使工地安全管理聚焦于PPE检测，传统人工巡检很难覆盖实时全面的监控需求，这直接促使深度学习自动化检测技术得到广泛应用。YOLO算法作为单阶段目标检测的典型代表，因实时性强、部署成本低而成为工地PPE检测的主流方案。但轻量级YOLO模型面对工地PPE检测场景表现欠佳。检测任务中遇到的工地小目标、复杂背景与目标遮挡难题，导致YOLO模型精度不足，PPE的漏检率与误检率居高不下，工程实际需求难以满足。标准YOLO框架缺乏针对工地环境的专门优化，C2HiLo-YOLO正是为填补这一空白而设计。本文在YOLO框架基础上引入注意力机制并重构网络结构，构建了轻量化且高性能的C2HiLo-YOLO检测模型。该模型经算法设计、实验验证与工程部署的完整流程检验，证明了其在工地PPE自动化检测中的实用性。由YOLO到C2HiLo-YOLO，这一改进过程产出了一系列研究成果。

本文的核心研究成果与创新点主要体现在三个方面。第一，本研究精准定位了轻量级YOLO模型在工地PPE检测中的技术瓶颈，明确了YOLOv11n作为基础框架的适配性与缺陷。通过对YOLOv11n的Backbone、Neck、Head三层架构的深入分析，发现其在处理工地高分辨率特征时，易被大面积低频背景信息主导，导致PPE小目标的高频细粒度特征被淹没，同时全局计算带来额外的算力开销，这个制约了模型的检测性能与实时性，为后续的定向优化奠定了基础。第二，本研究针对上述问题设计了适用于工地PPE检测的C2HiLo特征增强模块，实现了高低频特征的解耦与高效融合。该模块引入HiLo注意力机制，将特征处理分为高频局部与低频全局两个分支，高频分支通过局部窗口自注意力捕捉安全帽、反光背心等PPE目标的边缘、纹理等关键细节，低频分支通过池化下采样的全局注意力以低计算开销获取场景上下文，结合C2跨阶段局部网络的梯度分流设计，在过滤背景冗余干扰的同时，保证了模块的轻量化，解决了传统注意力机制“细节捕捉不足、计算开销大”的双重问题。第三，构建了C2HiLo-YOLO轻量化检测模型，实现了检测精度与实时性的极致平衡。在保留YOLOv11n核心架构与预训练权重迁移能力的基础上，将C2HiLo模块集成至Neck与Head的衔接处，对P4、P5深层融合特征进行定向增强，无需修改检测头结构即可实现即插即用。改进后的模型既通过高低频解耦注意力提升了对小目标、遮挡目标的检测能力，又仅小幅增加参数量与计算量，保持了轻量级模型的部署优势，打破了轻量化前馈网络“大感受野与高细节捕捉难以兼顾”的固有壁垒。

实验验证结果证实了本文研究方法的有效性。Construction-PPE和DPPE两个公开数据集上的对比实验显示，C2HiLo-YOLO在mAP50指标上较原始YOLOv11n有所提升，Recall指标改善，工地场景中PPE目标的漏检率降低，契合安全监管的实际需求。RT-DETR-L、YOLOv11m、YOLOv8m等中大型模型参数量与计算量高于C2HiLo-YOLO，C2HiLo-YOLO的检测精度接近甚至超越这些模型，精度效率比更高。消融实验确认C2HiLo模块是模型性能提升的主要因素。普通

C2结构或传统Transformer注意力提升检测精度时难以保证召回能力与实时性，C2HiLo模块提升检测精度并保持了召回能力与实时性，高低频解耦注意力机制适用于工地PPE检测任务。模型可视化分析表明C2HiLo-YOLO收敛速度快、训练过程稳定、类别区分能力强。小目标、密集遮挡、复杂背景等工地典型场景中，C2HiLo-YOLO能检出PPE目标，减少漏检与误检，检测效果优于原始YOLOv11n模型。

本文为工地PPE自动化检测提供了高效技术方案，把深度学习目标检测算法部署到建筑安全工程领域。但研究仍有局限。模型在极端光照（强光、逆光、夜间低光）与严重遮挡（目标被施工设备完全遮挡）场景下检测精度不足，后续可融合图像增强技术与多模态特征方法以增强模型在极端工况下的稳健性。手套、护目镜、安全鞋等更小尺寸PPE的检测精度仍需精化，设计更精细的多尺度特征融合结构并引入小目标检测专用增强策略是提升模型对微小PPE检出效能的有效手段。当前模型部署为本地端推理服务，尚未实现与工地现有监控系统的无缝耦合。后续将开展边缘端压缩优化（模型剪枝、量化），融合物联网与云计算技术，搭建工地安全管理平台，该平台整合实时检测、智能告警与数据统计功能，推动算法规模化工程应用。

总体而言，本文对YOLO算法进行了针对性改进，解决了轻量化YOLO模型在工地PPE检测时的关键难点。改进后的C2HiLo-YOLO模型在PPE检测精度与实时性上均获得显著增强，为工地安全管理智能化升级提供了技术支撑。深度学习在工业安全检测领域仍处于快速发展期，未来融合注意力机制、多模态数据融合、边缘计算等技术，将推动工地PPE检测向更高精度、更低延迟、更强智能的方向演进，为建筑行业安全生产提供保障。

致 谢

时光匆匆，本科四年的学习生涯即将结束，这篇毕业论文的完成，也为我的大学时光画上了圆满的句点。回首这段求学之路，从专业知识的积累到毕业设计的探索实践，每一步成长都离不开师长的悉心指导、亲友的温暖陪伴，在此，我谨向所有给予我帮助与支持的人，致以最诚挚的谢意。

首先，衷心感谢我的指导教师宋昕老师，在本次毕业设计的整个过程中，从论文选题、研究框架梳理到最终的撰写修改，宋老师都给予了我耐心的指导与专业的建议，让我能够顺利推进研究工作、完成论文写作。

同时，也感谢徐思洋老师、岳洋老师在求学和研究过程中为我提供的诸多帮助与指导，让我在本次毕业设计的学习和研究探索中收获良多。正是有了老师们的帮助与支持，这篇论文才得以顺利完成。

感谢东北大学秦皇岛分校的各位任课老师，本科四年里，各位老师在课堂上传道授业、悉心教导，不仅为我打下了扎实的专业基础，更培养了我科学的思维方式和自主学习、解决问题的能力，为本次毕业设计的顺利完成奠定了坚实的知识根基，这份师恩让我铭记于心。

感谢我的家人和好友，多年来，他们始终是我坚实的后盾，用无私的关爱、默默的理解和温暖的鼓励，给予我前行的动力。在完成论文的过程中，正是有了他们的支持，我才能全身心投入到研究与写作中，这份浓浓的亲情与友情，是我人生中最珍贵的财富。

毕业不是终点，而是新的人生起点。大学四年的所学所悟，都将成为我未来前行路上的宝贵经验。我将带着各位师长的教诲和亲友的期盼，在今后的道路上脚踏实地、笃行不怠，以更饱满的热情迎接新的挑战，用实际行动回报所有的关爱与支持。

本科期间论文项目情况

学术论文：

Li Songtao, and Tang Hao. Multimodal Alignment and Fusion: A Survey [J]. International Journal of Computer Vision ,2026,134:103.

Li Songtao, Zhang Yixuan, Bai Jie, Fan Kuan. DA34FL: A Robust Dynamic Accumulator-based Authentication and Key Agreement with Preserving Model Training Data Integrity for Federated Learning [J]. Scientific Reports ,2026,16:3660.

参考文献

[1]唐勇, 巫思敏. YOLOv3在安全帽佩戴检测中的应用[J]. 现代信息科技, 2021, 5(23): 88-91+95.

[2]侯卫民, 程婷婷, 何孟玲. 基于改进YOLOv5s的个人防护设备检测算法研究[J]. 长江信息通信, 2024, 37(06): 81-84.

[3]方伟立, 丁烈云. 工人不安全行为智能识别与矫正研究[J]. 华中科技大学学报: 自然科学版, 2022, 50(8): 5.

[4]秦妍, 梁臻, 娄阳. 一种基于YOLO v4和DeepSort的施工作业人员安全装备检测方法[J]. 科技创新与生产力, 2023, 44(10): 104-109.

[5]雷源毅, 朱文球, 廖欢. 复杂场景下的改进YOLOv8n安全帽佩戴检测算法[J]. 软件工程, 2023, 26(12): 46-51.

[6]Hinton G E, Salakhutdinov R R. Reducing the Dimensionality of Data with Neural Nnetworks [J]. Science, 2006, 313 (5786): 504-507.

[7]Long J, Shelhamer E, Darrell T. Fully Convolutional Networks for Semantic Segmentation [C]// 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) . Boston: IEEE, 2015: 3431-3440.

[8]Jiang P, Ergu D, Liu F, et al. A Review of Yolo algorithm developments[J]. Procedia computer science, 2022, 199: 1066-1073.

[9]张萌, 韩豫, 刘泽锋. 深度学习下建筑工人高空安全防护装备检测方法[J]. 中国安全科学学报, 2022, 32(05): 140-146.

[10]Chen C, Zheng Z, Xu T, et al. Yolo-based uav technology: A review of the research and its applications[J]. Drones, 2023, 7(3): 190.

[11]赵红成, 田秀霞, 杨泽森, 等. 改进YOLOv3的复杂施工环境下安全帽佩戴检测算法[J]. 中国安全科学学报 , 2022, 32(05): 194-200.

[12]Ferdous M, Ahsan S M M. PPE detector: a YOLO-based architecture to detect personal protective equipment (PPE) for construction sites[J]. PeerJ Computer Science, 2022, 8: e999.

[13]Zhang H, Mu C, Ma X, et al. MEAG-YOLO: a novel approach for the accurate detection of personal protective equipment in substations[J]. Applied Sciences, 2024, 14(11): 4766.

[14]Wu B, Pang C, Zeng X, et al. ME-YOLO: Improved YOLOv5 for detecting medical personal protective equipment[J]. Applied Sciences, 2022, 12(23): 11978.

[15]Guney E, Altin H, Asci A E, et al. YOLO-based personal protective equipment monitoring system for workplace safety[J]. JITSI: Jurnal Ilmiah Teknologi Sistem Informasi, 2024, 5(2): 77-85.

[16]李天宇, 吴浩, 毛艳玲, 等. 改进YOLOv4的安全帽佩戴检测方法[J]. 计算机工程与设计, 2023, 44(08):

2374-2381.

- [17]Zan J, Fang Y, Liu Q, et al. MKD-YOLO: Multi-Scale and Knowledge-Distilling YOLO for Efficient PPE Compliance Detection[C]//ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5.
- [18]许迪, 张淑卿, 葛超. 面向复杂环境的YOLOv8安全装备检测[J]. 电子测量技术, 2024, 47(07): 121-129.
- [19]Malaikrisanachalee S, Wongwai N, Kowcharoen E. ESPCN-YOLO: A High-Accuracy Framework for Personal Protective Equipment Detection Under Low-Light and Small Object Conditions[J]. Buildings, 2025, 15(10): 1609.
- [20]Nath N D, Behzadan A H, Paal S G. Deep learning for site safety: Real-time detection of personal protective equipment[J]. Automation in construction, 2020, 112: 103085.
- [21]Davoodi P, Gwon C, Lai G, et al. Tensorrt inference with tensorflow[C]//GPU Technology Conference. 2019.
- [22]Zou Z, Chen K, Shi Z, et al. Object detection in 20 years: A survey[J]. Proceedings of the IEEE, 2023, 111(3): 257-276.
- [23]Zhao Z Q, Zheng P, Xu S, et al. Object detection with deep learning: A review[J]. IEEE transactions on neural networks and learning systems, 2019, 30(11): 3212-3232.
- [24]Pang Y, Yuan Y, Li X, et al. Efficient HOG human detection[J]. Signal processing, 2011, 91(4): 773-781.
- [25]Wang X, Han T X, Yan S. An HOG-LBP human detector with partial occlusion handling[C]//International Conference on Computer Vision (ICCV). IEEE, 2009: 32-39.
- [26]Juan L, Gwun O. A comparison of sift, pca-sift and surf[J]. International Journal of Image Processing (IJIP), 2009, 3(4): 143-152.
- [27]Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.
- [28]Chua L O. CNN: A vision of complexity[J]. International Journal of Bifurcation and Chaos, 1997, 7(10): 2219-2425.
- [29]LeCun Y, Bengio Y. Convolutional networks for images, speech, and time series[J]. The handbook of brain theory and neural networks, 1998.
- [30]LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [31]Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on Computer Vision and Pattern Recognition (CVPR). 2014: 580-587.
- [32]Uijlings J R R, Van De Sande K E A, Gevers T, et al. Selective search for object recognition[J]. International journal of computer vision, 2013, 104(2): 154-171.
- [33]Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision.

2015: 1440-1448.

[34]Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.

[35]He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.

[36]Bharati P, Pramanik A. Deep learning techniques—R-CNN to mask R-CNN: a survey[J]. Computational Intelligence in Pattern Recognition: Proceedings of CIPR 2019, 2019: 657-668.

[37]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. Cham: Springer International Publishing, 2016: 21-37.

[38]Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection [C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788.

[39]Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.

[40]Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[EB/OL]. (2018-04-08)[2026-01-11]. <https://arxiv.org/abs/1804.02767>.

[41]Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.

[42]Khanam R, Hussain M. What is YOLOv5: A deep look into the internal features of the popular object detector[EB/OL]. (2024-07-30)[2026-01-11]. <https://doi.org/10.48550/arXiv.2407.20892>.

[43]胡文骏, 杨莉琼, 肖宇峰, 等. 识别安全帽佩戴的轻量化网络模型[J]. 计算机工程与应用, 2023, 59(13): 149-155.

[44]赵恩铭, 杨松, 罗创, 等. 基于YOLOv5s的施工人员安全防护设备佩戴检测研究[J]. 大理大学学报, 2022, 7(12): 37-42.

[45]李华, 薛曦澄, 吴立舟, 等. 深度学习下吊装作业工人防护装备及吊钩检测方法[J]. 安全与环境学报, 2024, 24(03): 1027-1035.

[46]汪侃, 刘嘉琳, 胡倩倩, 等. 多作业场景下个体防护装备自动检测研究[J]. 安全与环境学报, 2023, 23(11): 3960-3967.

[47]孙光灵, 黄磊, 吴倩. 基于KD-YOLO的轻量化安全帽佩戴检测方法[J]. 淮北师范大学学报(自然科学版), 2024, 45(02): 41-48.

[48]Tammina S. Transfer learning using vgg-16 with deep convolutional neural network for classifying images[J]. International Journal of Scientific and Research Publications (IJSRP), 2019, 9(10): 143-150.

- [49]He K, Zhang X, Ren S, et al. Identity mappings in deep residual networks[C]//European conference on computer vision. Cham: Springer International Publishing, 2016: 630–645.
- [50]Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [51]Fu C Y, Liu W, Ranga A, et al. DSSD: Deconvolutional Single Shot Detector[EB/OL]. (2017-01-24) [2026-01-11]. <https://arxiv.org/abs/1701.06659>.
- [52]Zhai S, Shang D, Wang S, et al. DF-SSD: An improved SSD object detection algorithm based on DenseNet and feature fusion[J]. IEEE access, 2020, 8: 24344–24357.
- [53]Li C, Li L, Jiang H, et al. YOLOv6: A Single-Stage Object Detection Framework for Industrial Applications[EB/OL]. (2022-09-07) [2026-01-11]. <https://doi.org/10.48550/arXiv.2209.02976>.
- [54]Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464–7475.
- [55]Sohan M, Sai Ram T, Rami Reddy C V. A review on yolov8 and its advancements[C]//International Conference on Data Intelligence and Cognitive Informatics. Springer, Singapore, 2024: 529–545.
- [56]Wang C Y, Yeh I H, Mark Liao H Y. Yolov9: Learning what you want to learn using programmable gradient information[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2024: 1–21.
- [57]Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984–108011.
- [58]Khanam R, Hussain M. YOLOv11: An Overview of the Key Architectural Enhancements[EB/OL]. (2024-10-23) [2026-01-11]. <https://doi.org/10.48550/arXiv.2410.17725>.
- [59]Khanam R, Hussain M. A Review of YOLOv12: Attention-Based Enhancements vs Previous Versions[EB/OL]. (2025-04-16) [2026-01-11]. <https://doi.org/10.48550/arXiv.2504.11995>.
- [60]Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132–7141.
- [61]Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [62]Jian Y, Yu J, Wen S, et al. Optimization of C2PSA Module in YOLOv11 Architecture for Semiconductor Wafer Inspection[C]//2025 International Conference on Advanced Mechatronic Systems (ICAMechS). 2025: 232–237. DOI:10.1109/ICAMechS68051.2025.11180983.
- [63]Chen X, Jiang N, Yu Z, et al. Citrus leaf disease detection based on improved YOLOv11 with C3K2[C]//International Conference on Computer Graphics, Artificial Intelligence, and Data Processing (ICCAID 2024). SPIE, 2025, 13560: 746–751.

- [64]Xiao R, Wang H, Wang L, et al. C3Ghost and C3k2: Performance study of feature extraction module for small target detection in YOLOv11 remote sensing images[C]//Second International Conference on Big Data, Computational Intelligence, and Applications (BDCIA 2024). SPIE, 2025, 13550: 464-470.
- [65]Pan Z, Cai J, Zhuang B. Fast vision transformers with hilo attention[J]. Advances in neural information processing systems, 2022, 35: 14541-14554.
- [66]DALVI M, SINGH N, BHINGARDE S, et al. Construction-PPE: Personal Protective Equipment Detection Dataset[DB/OL]. Version 1.0.0. Ultralytics, 2025[2025-10-11]. <https://docs.ultralytics.com/datasets/detect/construction-ppe/>.
- [67]HUANG M L, CHENG Y. Dataset of Personal Protective Equipment (PPE)[DB/OL]. V6. Mendeley Data, 2025. doi:10.17632/zkzghjvp2.6.

须知：

- 报告编号系送检论文检测报告在本系统中的唯一编号。
- 本报告结合AI大模型自动生成，结果仅供参考。
- 报告支持中、英文内容检测。



微信公众号

唯一官网: <https://vpcs.fanyu.com> | 客服邮箱: vpcs@fanyu.com | 客服热线: 400-607-5550 | 客服QQ: 4006075550